

# LAPORAN ANALISIS BIAS DATASET ADULT INCOME PADA SISTEM KREDIT BERBASIS AI

Oleh: Dasilfa Putri Ramdhany | NIM: 2553150013

## 1. ANALISIS KETIMPANGAN DATA (EVIDENCE-BASED DATA ANALYSIS)

Berdasarkan pengolahan dataset Adult Income (UCI Machine Learning Repository) menggunakan library Pandas, ditemukan ketimpangan struktural yang signifikan pada distribusi pendapatan (>50K per tahun) antar kelompok demografi:

- a. Ketimpangan Berdasarkan Gender:
  - 1) Laki-Laki (Male): 30.57% memiliki pendapatan >50K.
  - 2) Perempuan (Female): Hanya 10.95% memiliki pendapatan >50K.
  - 3) Temuan: Kelompok laki-laki hampir 3 kali lipat lebih berpeluang memiliki label pendapatan tinggi dibanding perempuan pada data historis ini
- b. Ketimpangan Berdasarkan Ras:
  - 1) Asian-Pac-Islander: 26.56% (>50K)
  - 2) White: 25.59% (>50K)
  - 3) Black: 12.39% (>50K)
  - 4) Amer-Indian-Eskimo: 11.58% (>50K)
  - 5) Other: 9.26% (>50K)
  - 6) Temuan: Kelompok ras minoritas (seperti Black, Amer-Indian, dan Other) tercatat memiliki proporsi penghasilan tinggi kurang dari setengah populasi White/Asian.

## 2. RISIKO PENGGUNAAN DATA UNTUK MODEL AI PENYETUJU KREDIT

Jika dataset historis ini digunakan langsung tanpa perlakuan khusus untuk melatih sistem persetujuan kredit pinjaman berbasis AI, maka timbul risiko serius:

- a. Mewarisi & Mengamplifikasi Bias Historis (Amplification of Bias):

Model Machine Learning bekerja dengan mencari pola matematis dari masa lalu. Karena data historis menunjukkan perempuan dan kelompok ras minoritas memiliki persentase gaji tinggi yang rendah, model akan menyimpulkan bahwa atribut gender/ras tersebut berisiko tinggi. Keputusan kredit di masa depan otomatis akan terus mendiskriminasi kelompok ini.

- b. Ancaman Variabel Proxy (Implicit Bias via Proxy Variables):

Meskipun variabel eksplisit seperti 'sex' atau 'race' dihapus dari dataset, model tetap dapat menangkap bias melalui variabel proxy seperti 'occupation', 'hours-per-week', atau 'zip-code/native-country'. Atribut-atribut ini secara implisit merepresentasikan stereotip historis dan kondisi sosio-ekonomi kelompok tertentu.

c. Lingkaran Setan Keterbelakangan Ekonomi (Feedback Loop):

Penolakan pinjaman otomatis oleh AI kepada kelompok terdampak akan menghambat akses modal investasi atau bisnis mereka. Hal ini memperparah ketimpangan ekonomi dan kembali terekam sebagai data buruk di masa depan

### 3. USULAN STRATEGI MITIGASI BIAS (DEBIASING STRATEGIES)

Untuk mencegah diskriminasi matematis pada sistem AI persetujuan kredit, beberapa langkah teknik dan etis wajib diterapkan:

- a. Pre-processing (Fair Representation & Data Re-weighting):
  - 1) Menerapkan re-sampling atau synthetic data generation (SMOTE) untuk meningkatkan sampel positif pada kelompok minoritas/terdampak.
  - 2) Menerapkan teknik Re-weighting, yaitu memberi bobot lebih tinggi pada sampel terwakili yang bernilai positif (misal: memberi bobot kredit tinggi bagi perempuan/ras minoritas bernilai positif dalam data latihan).
- b. In-processing (Fairness Constraints during Training):
  - 1) Menambahkan penalti/kontrain keadilan (Fairness Constraints) pada fungsi kerugian (Loss Function) model, seperti memaksa kriteria Demographic Parity atau Equalized Odds.
- c. Post-processing & Audit Transparansi:
  - 1) Melakukan evaluasi metrik keadilan khusus (misal: Disparate Impact Ratio) secara rutin sebelum model dideploy ke sistem produksi.
  - 2) Menerapkan Explainable AI (XAI) seperti SHAP atau LIME agar setiap keputusan penolakan kredit dapat dijelaskan alasannya secara rasional dan transparan tanpa menyudutkan demografi pengguna.